

DSAA2011 Student Dropout Project Report

2026 Spring


Introduction

本项目基于 UCI **Predict Students' Dropout and Academic Success** 数据集完成学生辍学分析。数据包含 4424 名本科学生、36 个原始特征，目标变量为 Dropout、Enrolled 与 Graduate，其中 Dropout=1421、Enrolled=794、Graduate=2209。分析路线为：先进行缺失值、类别变量和标准化处理，再用 t-SNE 与聚类观察高维结构，最后将任务转为 Dropout vs Graduate 二分类，比较逻辑回归、决策树和随机森林，并补充校准、干预覆盖、公平性与错误案例分析。

1. Data Preprocessing

缺失值检查显示最大缺失率为 0.00%，没有列超过 40% 阈值，因此未删除特征。数值型变量使用中位数填充，类别型变量使用众数填充；18 个类别变量经独热编码处理，其中 Application mode, Course, Father's occupation, Father's qualification, Mother's occupation, Mother's qualification, Nationality, Previous qualification 等高基数变量只保留 Top 5 类别，其余归为 Other。标准化前特征矩阵为 [4424, 36]，处理后为 [4424, 96]。该流程兼顾异常值鲁棒性、类别变量可建模性和不同量纲特征的可比性。

2. Data Visualization and Clustering



t-SNE projection

t-SNE 使用 `perplexity=30`、`learning_rate=200`、`random_state=42`。二维嵌入显示三类样本存在局部聚集，但整体交叠明显：Dropout 在若干区域密度较高，Graduate 在中心和右下区域较集中，Enrolled 常落在两者之间。这说明学生状态与早期学业、经济和人口统计变量相关，但并不存在简单线性边界。Enrolled 标签代表尚未结束的学业过程，其混合分布也支持后续二分类中剔除该类的决定。


K-Means 与 Ward 层次聚类均在 $K=2$ 至 8 中搜索，K-Means 用肘部法则和轮廓系数选择 K ，层次聚类结合树状图和轮廓系数。结果如下：

algorithm

K-Means

Agglomerative Ward

层次聚类的 `silhouette=0.411`，内部距离分离较强；但其 ARI 仅 0.001，几乎不能复现真实学业结局。K-Means 的 CH 指数和 ARI 更高，虽 `silhouette` 较低，但与 Target 的对应关系更强。因此若目标是辅助理解学生结果结构，K-Means 更有实用价值；若只看内部距离分离，Ward 层次聚类更占优。



Cluster comparison on t-SNE

3. Prediction: Training and Testing

监督学习将 Target 转为二分类：Dropout 为正类，Graduate 为负类。Enrolled 样本被剔除，因为该类学生最终结果尚不明确，作为监督标签会降低模型置信度。二分类数据包含 Graduate=2209、Dropout=1421，采用 70%/30% 分层抽样。逻辑回归作为稳定线性基线，决策树设置 max_depth=5 以限制过拟合。测试集混淆矩阵显示逻辑回归漏判 Dropout 50 人，决策树漏判 84 人，逻辑回归更适合辍学预警。

Logistic Regression

Logistic Regression: Confusion Matrices

	Train		Test		Full	
Actual \ Predicted	Graduate	Dropout	Graduate	Dropout	Graduate	Dropout
Actual Graduate	1473	73	629	34	2102	107
Actual Dropout	155	840	50	376	205	1216


4. Evaluation and Model Choice

测试集指标如下：

model

Logistic Regression

Decision Tree



ROC curves

逻辑回归在 Accuracy=0.923、Recall=0.883、F1=0.900、AUC=0.964 上均优于或明显优于决策树。5 折交叉验证中，逻辑回归 AUC=0.951±0.006，决策树 AUC=0.914±0.004。逻辑回归训练准确率 0.910、测试准确率 0.923，泛化稳定；决策树训练准确率 0.913、测试准确率 0.894，差距不大但 Recall 偏低。综合排序能力、漏报控制和交叉验证稳定性，逻辑回归是本任务中最合适的简单模型。

5. Open-ended Exploration

5.1 Feature Importance, Model Comparison, and Imbalance

随机森林 impurity importance 的 Top 5 如下，主要集中在两个学期的通过课程数、成绩与学费状态，具有明确教育解释：学业完成度低和财务压力会同时提高辍学风险。

original_feature

Curricular units 2nd sem (approved)

Curricular units 1st sem (approved)

Curricular units 2nd sem (grade)

Curricular units 1st sem (grade)

Tuition fees up to date

随机森林使用 GridSearchCV 调整 `n_estimators`、`max_depth` 与 `min_samples_leaf`，最佳参数为 `{'rf__max_depth': None, 'rf__min_samples_leaf': 1, 'rf__n_estimators': 300}`。三类模型测试集表现如下：


model

Logistic Regression

Random Forest, tuned


Decision Tree

调参随机森林 $AUC=0.958$ ，优于决策树但略低于逻辑回归，说明复杂模型未必带来更高泛化收益。类别不平衡方面，Dropout/Graduate 比例为 0.643；SMOTE 将逻辑回归 Recall 从 0.883 提升到 0.904，但 AUC 略降，因此更适合“少漏报”优先的策略，而非默认替代原始模型。



Model and feature comparison

5.2 Early Warning and Intervention Value



Early warning comparison


早期预警实验严格控制信息可用时间点。只使用入学时已知信息时， $AUC=0.838$ 、 $Recall=0.634$ ；加入第一学期表现后， AUC 提升到 0.939 、 $Recall$ 提升到 0.852 ；再加入第二学期后， $AUC=0.964$ 、 $Recall=0.883$ 。因此，完整模型更像回顾性诊断，而 Enrollment + 1st semester 模型更适合可行动预警。

experiment

Enrollment only

Enrollment + 1st semester


Enrollment + 1st + 2nd semester



Intervention coverage

干预覆盖曲线比 ROC 更接近教育管理场景。使用第一学期可行动模型时，跟进风险最高的 25% 学生可覆盖 62.68% 的真实 Dropout，名单中的 Dropout 比例为 97.80%；完整模型对应覆盖率为 63.85%。两者差距不大，说明第一学期模型已经足以支持有限资源下的优先排序。若设定 top-25% 容量策略，完整逻辑回归在测试集中标记 272 人， $Precision=0.996$ 、 $Recall=0.636$ 。

5.3 From Correlation to Trustworthy Explanation



Calibration curves

为了判断风险分是否可解释为概率，本项目绘制校准曲线并计算 Brier score。结果如下：

model

Logistic Regression

Decision Tree

Random Forest, tuned

逻辑回归的 Brier score=0.058，低于决策树和调参随机森林，说明其概率输出更适合解释为辍学风险。进一步使用 CalibratedClassifierCV 后，最佳 Brier score 来自 Logistic Regression, isotonic，为 0.057。PDP 显示，当 Curricular units 2nd sem (approved) 从 0 增至 6 时，随机森林平均预测风险由 0.652 降至 0.310；Tuition fees up to date 从 0 变为 1 时，风险由 0.648 降至 0.387。反事实风格模拟中，“学费按时缴纳 + 第二学期通过课程数增加 3”使平均风险下降 0.166。这些结果适合生成干预假设，但仍不是因果估计。

5.4 Uncertainty, Fairness, and Error Cases

模型总体指标使用 1000 次 bootstrap 估计 95% 置信区间：

model

Logistic Regression

逻辑回归 AUC 的 95% CI 为 0.964 [0.951, 0.976], Recall 的 95% CI 为 0.883 [0.853, 0.912], 总体较稳健。公平性分析按 Gender、International 与 Scholarship holder 分组计算 Recall、FPR、Brier score 和 group-wise calibration ; International=1 组仅 27 人, Recall=0.846, Wilson 95% CI 为 [0.578, 0.957], bootstrap Recall 95% CI 为 [0.615, 1.000], 因此不应过度解读小样本群体的点估计。错误案例方面, 逻辑回归漏判 50 名 Dropout ; 漏判者在 Curricular units 2nd sem (approved) 上均值为 5.720, 高于正确识别 Dropout 的 1.213, 说明部分辍学学生在结构化学业和财务变量上看似安全, 仍需人工复核和非结构化信息补充。

Conclusion

无监督分析表明三类学业结果有局部结构但重叠明显, 不能仅靠自然聚类替代监督预测。监督学习中, 逻辑回归以 AUC=0.964 和 Recall=0.883 成为最佳简单模型; 调参随机森林作为开放探索模型接近逻辑回归但未超过它。更深入的开放探索显示, 第一学期信息已能将 AUC 从 0.838 提升到 0.939, 是早期预警的关键时间点; 第二学期通过课程数、学费状态和第一学期通过课程数是最核心因素。干预覆盖曲线、校准后模型、bootstrap 公平性区间、时间泄漏讨论和错误案例画像进一步说明, 模型可以支持风险排序和干预假设, 但部署时必须同时报告概率校准、群体差异、不确定性和模型失败模式。

References

1. UCI Machine Learning Repository. Predict Students' Dropout and Academic Success.
<https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>
2. Pedregosa et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.
3. van der Maaten and Hinton. Visualizing Data using t-SNE. Journal of Machine Learning Research, 2008.