


DSAA2011 Student Dropout Project Report

Reference Answer for Teaching and Grading

2026 Spring

Introduction

本项目基于 UCI 的 **Predict Students' Dropout and Academic Success** 数据集完成 DSAA2011 项目要求。数据包含 4424 名本科学生、36 个原始特征，目标变量为 Dropout、Enrolled 与 Graduate，其中 Dropout=1421、Enrolled=794、Graduate=2209。项目先用无监督方法观察高维结构，再将任务转化为 Dropout 与 Graduate 二分类，以便建立可解释的辍学预警模型。




Target distribution

1. Data Preprocessing

缺失值检查显示最大缺失率为 0.00%，没有列超过 40% 阈值，因此未删除特征。数值型变量使用中位数填充，类别型变量使用众数填充；18 个类别变量经独热编码处理，其中 Application mode, Course, Father's occupation, Father's qualification, Mother's occupation, Mother's qualification, Nacionality, Previous

qualification 等高基数变量只保留 Top 5 类别，其余归为 Other。标准化前特征矩阵为 [4424, 36]，处理后为 [4424, 96]。该流程兼顾异常值鲁棒性、类别变量可建模性和不同量纲特征的可比性。


2. Data Visualization: t-SNE




t-SNE projection

t-SNE 使用 perplexity=30、learning rate=200、random state=42。二维嵌入显示三类样本存在局部聚集，但整体交叠明显：Dropout 在若干区域密度较高，Graduate 在中心和右下区域较集中，Enrolled 常落在两者之间。这说明学生状态与早期学业、经济和人口统计变量相关，但并不存在简单线性边界。Enrolled 标签代表尚未结束的学业过程，其混合分布也支持后续二分类中剔除该类的决定。

3. Clustering Analysis



K-Means selection



Hierarchical dendrogram

K-Means 与 Ward 层次聚类均在 K=2 至 8 中搜索，K-Means 用肘部法则和轮廓系数选择 K，层次聚类结合树状图和轮廓系数。结果如下：

algorithm

K-Means

Agglomerative Ward

层次聚类的 silhouette=0.411，内部距离分离较强；但其 ARI 仅 0.001，几乎不能复现真实学业结局。K-Means 的 CH 指数和 ARI 更高，虽 silhouette 较低，但与 Target 的对应关系更强。因此若目标是辅助理解学生结果结构，K-Means 更有实用价值；若只看内部距离分离，Ward 层次聚类更占优。




Cluster comparison on t-SNE

4. Prediction: Training and Testing


监督学习将 Target 转为二分类：Dropout 为正类，Graduate 为负类。Enrolled 样本被剔除，因为该类学生最终结果尚不明确，作为监督标签会降低模型置信度。二分类数据包含 Graduate=2209、Dropout=1421，采用 70%/30% 分层抽样。逻辑回归作为稳定线性基线，决策树设置 `max_depth=5` 以限制过拟合。测试集混淆矩阵显示逻辑回归漏判 Dropout 50 人，决策树漏判 84 人，逻辑回归更适合辍学预警。

Logistic Regression: Confusion Matrices



Logistic regression confusion matrices

Decision Tree: Confusion Matrices



Decision tree confusion matrices


5. Evaluation and Model Choice

测试集指标如下：

model

Logistic Regression

Decision Tree



ROC curves

逻辑回归在 Accuracy=0.923、Recall=0.883、F1=0.900、AUC=0.964 上均优于或明显优于决策树。5 折交叉验证结果如下：

model


Logistic Regression

Decision Tree

逻辑回归训练准确率 0.910，测试准确率 0.923，泛化稳定。决策树训练准确率 0.913，测试准确率 0.894，差距不大但 Recall 偏低。综合 AUC、Recall 与交叉验证稳定性，逻辑回归是本任务中最合适的简单模型。

6. Open-ended Exploration

6.1 Feature Importance and Model Comparison



Top feature importance

随机森林 impurity importance 的 Top 5 如下：

original_feature

Curricular units 2nd sem (approved)

Curricular units 1st sem (approved)

Curricular units 2nd sem (grade)

Curricular units 1st sem (grade)

Tuition fees up to date

随机森林使用 GridSearchCV 调整 `n_estimators`、`max_depth` 与 `min_samples_leaf`，最佳参数为 `{'rf__max_depth': None, 'rf__min_samples_leaf': 1, 'rf__n_estimators': 300}`。三类模型测试集表现如下：


model

Logistic Regression

Random Forest, tuned

Decision Tree

调参随机森林 AUC=0.958，优于决策树但略低于逻辑回归。该结果说明本数据中辍学与毕业之间存在较强的近线性可分信号，复杂模型未必带来更高泛化收益。



Model comparison

6.2 Class Imbalance and SMOTE

二分类任务的少数类/多数类比例为 0.643，存在中等不平衡。SMOTE 结果如下：


model

Logistic Regression + SMOTE

Decision Tree + SMOTE

SMOTE 将逻辑回归 Recall 从 0.883 提升到 0.904，但 Precision 与 AUC 略降；对决策树，AUC 提升约 0.020。若实际场景重视少漏报，SMOTE 值得考虑；若强调整体排序能力，原始逻辑回归已足够稳健。

6.3 Early Warning Experiment



Early warning comparison

早期预警实验严格控制信息可用时间点。只使用入学时已知信息时，AUC=0.838、Recall=0.634；加入第一学期表现后，AUC 提升到 0.939、Recall 提升到 0.852；再加入第二学期后，AUC=0.964、Recall=0.883。这说明第一学期信息已经提供了大部分预测增益，第二学期继续提升但边际收益较小。从教育干预角度，第一学期结束后建模比等到第二学期结束更有实际价值。


experiment	n_raw_features	accuracy	precision	recall	f1	AUC	AUC_gain_vs_enrollment_only
Enrollment only	24	0.769	0.738	0.634	0.682	0.838	0.000
Enrollment + 1st semester	30	0.902	0.892	0.852	0.872	0.939	0.101
Enrollment + 1st + 2nd semester	36	0.923	0.917	0.883	0.900	0.964	0.126

6.3.1 Prediction Time Matters

experiment	n_raw_features	AUC	recall	precision	f1	interpretation	leakage_risk_for_early_intervention
Enrollment only	24	0.838	0.634	0.738	0.682	Pre-enrollment screening; useful for planning, weak for precise intervention.	Low
Enrollment + 1st semester	30	0.939	0.852	0.892	0.872	Actionable early warning; available after first-semester outcomes.	Low
Enrollment + 1st + 2nd semester	36	0.964	0.883	0.917	0.900	Retrospective diagnosis; strongest accuracy but may be late for prevention.	High if claimed as early warning

若报告声称“早期预警”，则不能使用第二学期结束后的表现作为输入，否则存在时间泄漏。完整模型 AUC 最高，但它回答的是“哪些学生最终更像辍学者”的回顾性诊断问题；第一学期模型回答的是“还有时间干预时，哪些学生值得优先关注”的管理问题。因此，本项目在部署建议中优先使用 Enrollment + 1st semester 模型，在技术上保留 full model 作为上界参考。

6.4 Feature Ablation



Feature ablation

消融实验从完整特征集中按组删除人口统计、经济状态、第一学期和第二学期特征。结果显示，删除第二学期特征使 AUC 下降 0.025，删除两个学期特征使 AUC 下降 0.126、Recall 下降 0.249。经济状态删除后 AUC 下降 0.009，说明缴费、欠费、奖学金和宏观经济变量有辅助价值。人口统计变量删除后几乎不降低 AUC，不应被过度解读为主要风险来源。

experiment

Full features

Remove demographics


Remove economic status

Remove 1st semester

Remove 2nd semester

Remove both semesters


6.5 Threshold Tuning and Intervention Strategy



Threshold tuning

默认阈值 0.5 并不一定符合学校资源约束。若设定“每 100 名学生最多人工跟进 25 人”，最合理策略是按模型风险分从高到低排序并跟进前 25%。在测试集中该策略标记 272 人，Precision=0.996、Recall=0.636、F1=0.777。这意味着少量人工资源可以优先覆盖最高风险学生，但会牺牲一部分 Recall；若目标是尽量少漏报，则应降低阈值并接受更多人工审核。

6.5.1 Intervention Coverage Curve



Intervention coverage

干预覆盖曲线直接回答“跟进多少学生能覆盖多少真实 Dropout”。使用第一学期可行动模型时，跟进风险最高的 25% 学生可覆盖 62.68% 的真实 Dropout，跟进名单中的 Dropout 比例为 97.80%；使用包含第二学期信息的完整模型时，对应覆盖率为

63.85%。两者在前 25% 容量下差距不大，说明第一学期模型已经足以支持实际干预排序，而第二学期模型更适合作为回顾性诊断。

model	follow_u p_rate	follow_u p_count	captured _dropout	dropout_ coverag e	precisio n_among _followe _d	lift_vs_ra ndom
Actionable LR, enrollment + 1st semester	0.050	55	55	0.129	1.000	2.556
Actionable LR, enrollment + 1st semester	0.100	109	108	0.254	0.991	2.533
Actionable LR, enrollment + 1st semester	0.150	164	163	0.383	0.994	2.541
Actionable LR, enrollment + 1st semester	0.200	218	216	0.507	0.991	2.533
Actionable LR, enrollment + 1st semester	0.250	273	267	0.627	0.978	2.500
Actionable LR, enrollment + 1st semester	0.300	327	316	0.742	0.966	2.470
Actionable LR, enrollment + 1st semester	0.400	436	371	0.871	0.851	2.175

le LR,
enrollme
nt + 1st
semeste
r

Actionab le LR, enrollme nt + 1st semeste r	0.500	545	389	0.913	0.714	1.825
--	-------	-----	-----	-------	-------	-------

Full LR, enrollme nt + 1st + 2nd semeste r	0.050	55	55	0.129	1.000	2.556
---	-------	----	----	-------	-------	-------

Full LR, enrollme nt + 1st + 2nd semeste r	0.100	109	108	0.254	0.991	2.533
---	-------	-----	-----	-------	-------	-------

Full LR, enrollme nt + 1st + 2nd semeste r	0.150	164	163	0.383	0.994	2.541
---	-------	-----	-----	-------	-------	-------


Full LR, enrollme nt + 1st + 2nd semeste r	0.200	218	217	0.509	0.995	2.545
---	-------	-----	-----	-------	-------	-------

Full LR, enrollme nt + 1st + 2nd semeste r	0.250	273	272	0.638	0.996	2.547
---	-------	-----	-----	-------	-------	-------

Full LR, enrollme nt + 1st	0.300	327	322	0.756	0.985	2.517
----------------------------------	-------	-----	-----	-------	-------	-------

+ 2nd semester						
Full LR, enrollment + 1st + 2nd semester	0.400	436	384	0.901	0.881	2.251
Full LR, enrollment + 1st + 2nd semester	0.500	545	408	0.958	0.749	1.914

6.6 Permutation Importance



Permutation importance

由于 impurity importance 对高基数独热特征可能存在偏差，本项目额外使用 permutation importance，以测试集 AUC 下降衡量原始特征贡献。结果如下：

feature

Curricular units 2nd sem (approved)


Tuition fees up to date

Curricular units 1st sem (approved)

Curricular units 2nd sem (grade)
 Scholarship holder
 Course
 Curricular units 1st sem (grade)
 Curricular units 1st sem (enrolled)

Permutation importance 仍将第二学期通过课程数列为最重要特征，置乱后 AUC 平均下降 0.062；Tuition fees up to date 的 AUC 下降为 0.017，进一步支持“学业表现 + 经济状态”双重解释。

6.7 Fairness Check



Fairness group metrics


按 Gender、International 和 Scholarship holder 分组后，逻辑回归在不同群体上的 Recall 和 FPR 存在差异：

sensitive_feature	group_value	n	positive_s_dropout	recall	FPR	precision	mean_predicted_risk
Gender	0	669	199	0.849	0.030	0.923	0.317
Gender	1	420	227	0.912	0.104	0.912	0.571
International	0	1062	413	0.884	0.052	0.915	0.414
International	1	27	13	0.846	0.000	1.000	0.445
Scholarship holder	0	822	390	0.887	0.065	0.925	0.492

Scholarship holder	1	267	36	0.833	0.026	0.833	0.179
--------------------	---	-----	----	-------	-------	-------	-------

Gender=1 的 Recall=0.912，高于 Gender=0 的 0.849，但其 FPR 也更高。Scholarship holder=1 的 Recall=0.833，低于非奖学金组。International=1 的样本仅 27 人，结论应谨慎。若模型部署为真实预警系统，应继续做群体校准和人工复核。

6.7.1 Fairness Bootstrap Confidence Intervals




Fairness bootstrap CI

在 Wilson 区间之外，本项目还对每个敏感群体内的 Recall 和 FPR 做 bootstrap。International=1 组只有 27 个测试样本，其 Recall bootstrap 95% CI 为 [0.615, 1.000]。这进一步说明，小样本群体的公平性指标不应只看点估计；真实部署时需要持续积累样本并周期性重估。

sensitive_feature	group_value	n	recall_bootstrap_mean	recall_ci_low	recall_ci_high	FPR_bootstrap_mean	FPR_ci_low	FPR_ci_high
Gender	0	669	0.849	0.798	0.896	0.029	0.015	0.046
Gender	1	420	0.913	0.874	0.948	0.104	0.065	0.146
International	0	1062	0.883	0.853	0.913	0.052	0.036	0.069
International	1	27	0.848	0.615	1.000	0.000	0.000	0.000

Scholarship holder	0	822	0.887	0.855	0.917	0.064	0.042	0.087
Scholarship holder	1	267	0.833	0.704	0.947	0.026	0.008	0.049

6.8 Reusing Enrolled Students as Risk-scoring Cases



Enrolled risk distribution

Enrolled 样本不适合作为监督训练标签，但可用“入学 + 第一学期”模型打风险分。794 名 Enrolled 学生的平均风险为 0.452，中位数为 0.400；其中 333 人风险分不低于 0.5，占 41.94%。若采用早期模型在测试集上的 top-25% 阈值 0.915，Enrolled 中仍有 95 人进入高优先级干预名单，占 11.96%。风险分桶如下：

risk_bucket


low_<0.25

very_high_>=0.75

medium_0.25-0.50

high_0.50-0.75

6.9 Calibration and Brier Score




Calibration curves

为了判断风险分是否可解释为概率，本项目绘制校准曲线并计算 Brier score。结果如下：


model	brier_score	expected_calibration_error	max_calibration_error	mean_predicted_risk	observed_dropout_rate
Logistic Regression	0.058	0.031	0.223	0.415	0.391
Decision Tree	0.089	0.025	0.150	0.400	0.391
Random Forest, tuned	0.068	0.062	0.206	0.403	0.391

逻辑回归的 Brier score=0.058，低于决策树和调参随机森林，说明其概率输出更适合直接解释为辍学风险。其 expected calibration error=0.031，整体校准较好，但校准曲线在中高风险区仍有偏差。因此在真实部署中，风险分可以用于排序和分层，但不应机械地解释为完全准确的个人概率。

6.9.1 Calibrated Models



Calibrated model curves




Calibrated model comparison

进一步使用 CalibratedClassifierCV 对逻辑回归和决策树进行 Platt scaling 与 isotonic calibration。结果如下：

model	calibration_method	AUC	brier_score	expected_calibration_error	mean_predicted_risk
Logistic Regression, uncalibrated	none	0.964	0.058	0.031	0.415
Logistic Regression, Platt	sigmoid	0.964	0.059	0.042	0.414
Logistic Regression, isotonic	isotonic	0.965	0.057	0.033	0.416
Decision Tree, uncalibrated	none	0.906	0.089	0.025	0.400
Decision Tree, Platt	sigmoid	0.948	0.079	0.056	0.402
Decision Tree, isotonic	isotonic	0.947	0.077	0.046	0.404


本次结果中，最佳 Brier score 来自 Logistic Regression, isotonic，为 0.057；最佳 ECE 来自 Decision Tree, uncalibrated，为 0.025。校准改善了部分概率质量，尤其是决策树的 Brier score，但校准方法也可能改变排序表现，因此部署时应同时报告 AUC、Brier 和 ECE，而不是只优化单一指标。

6.10 Partial Dependence and Counterfactual-style Discussion



Partial dependence

Partial dependence 显示，当 Curricular units 2nd sem (approved) 从 0 增至 6 时，随机森林平均预测风险由 0.652 降至 0.310；Tuition fees up to date 从 0 变为 1 时，平均风险由 0.648 降至 0.387。这支持“课程通过数量”和“学费状态”是关键风险信号，但 PDP 仍是模型解释，不等同于因果效应。




Counterfactual scenarios

反事实风格模拟使用逻辑回归模型在测试集上修改单个或少量特征，观察预测风险变化：

scenario	n_eligible	baseline_ mean_risk_ _eligible	scenario_ mean_risk_ _eligible	mean_delt a_risk	pct_with_l ower_risk
Set unpaid tuition to up-to-date	154	0.941	0.819	-0.122	1.000
Increase 2nd-sem approved units by +1	1089	0.415	0.360	-0.056	1.000
Increase 2nd-sem approved units by +3	1089	0.415	0.277	-0.138	1.000
Tuition up-to-date and approved units +3	1089	0.415	0.249	-0.166	1.000

模拟显示，将第二学期通过课程数增加 3 个单位时，平均预测风险下降 0.138；同时将学费状态设为按时缴纳并增加 3 个通过课程时，平均风险下降 0.166。这些结果适合用于形成教育干预假设，例如加强课程支持和学费援助，但不能替代随机实验或因果推断。

6.11 Deployment Uncertainty and Group-wise Calibration



Bootstrap metric CI

模型总体指标使用 1000 次 bootstrap 估计 95% 置信区间：


model

Logistic Regression

Decision Tree

Random Forest, tuned

逻辑回归 AUC 的 95% CI 为 0.964 [0.951, 0.976], Recall 的 95% CI 为 0.883 [0.853, 0.912]。这说明其总体性能较稳健，但 Recall 仍有不确定性。



Group-wise calibration


分组校准结果如下：

sensitive_feature	group_value	n	observed_dropout_rate	mean_predicted_risk	calibration_gap_pred_minus_observed	brier_score
Gender	0	669	0.297	0.317	0.020	0.055
Gender	1	420	0.540	0.571	0.031	0.064
International	0	1062	0.389	0.414	0.026	0.059
International	1	27	0.481	0.445	-0.037	0.045
Scholarship holder	0	822	0.474	0.492	0.018	0.065
Scholarship holder	1	267	0.135	0.179	0.044	0.038

holder

International=1 组仅 27 人，Recall=0.846，Wilson 95% CI 为 [0.578, 0.957]；FPR=0.000，但 95% CI 上界达到 0.215。这说明小样本群体的点估计不可过度解读。部署时应报告不确定性、进行人工复核，并在积累更多样本后重新评估群体校准。

6.12 False Negative Profile



False negative profile

最后分析逻辑回归在测试集上漏判的 Dropout。模型共漏判 50 名 Dropout，正确识别 376 名 Dropout。漏判样本最突出的特征差异是 Curricular units 2nd sem (approved)：漏判组均值为 5.720，正确识别组均值为 1.213。总体上，漏判学生往往第二学期通过课程数更高、学费状态更正常、欠费比例更低，因而在表格特征上更像 Graduate。这提示学校不能只依赖模型风险分，还应结合退学申请、转专业、个人原因等非结构化信息。

feature	false_negative_mean	true_positive_mean	all_dropout_mean	fn_minus_tp	standardized_fn_minus_tp
Curricular units 2nd sem (approved)	5.720	1.213	1.742	4.507	1.815
Curricular units 1st sem (approved)	6.220	1.867	2.378	4.353	1.555

)					
Curricular units 2nd sem (grade)	12.004	4.800	5.645	7.205	1.173
Curricular units 1st sem (grade)	11.925	6.445	7.088	5.480	0.908
Tuition fees up to date	1.000	0.612	0.657	0.388	0.818
Curricular units 1st sem (enrolled)	7.000	5.723	5.873	1.277	0.586
Curricular units 2nd sem (enrolled)	6.880	5.721	5.857	1.159	0.569
Debtor	0.040	0.255	0.230	-0.215	-0.512

Conclusion

无监督分析表明三类学业结果有局部结构但重叠明显，不能仅靠自然聚类替代监督预测。监督学习中，逻辑回归以 $AUC=0.964$ 和 $Recall=0.883$ 成为最佳简单模型；调参随机森林作为开放探索模型接近逻辑回归但未超过它。更深入的开放探索显示，第一学期信息已能将 AUC 从 0.838 提升到 0.939 ，是早期预警的关键时间点；第二学期通过课程数、学费状态和第一学期通过课程数是最核心因素。干预覆盖曲线、校准后模型、bootstrap 公平性区间、时间泄漏讨论和错误案例画像进一步说明，模型可以支持风险排序和干预假设，但部署时必须同时报告概率校准、群体差异、不确定性和模型失败模式。

References

1. UCI Machine Learning Repository. Predict Students' Dropout and Academic Success.
<https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>
2. Pedregosa et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.
3. van der Maaten and Hinton. Visualizing Data using t-SNE. Journal of Machine Learning Research, 2008.

Credit

This is a reference answer prepared for teaching and grading standardization. GenAI assistance was used to draft and format the reference materials; all numeric results are generated by the reproducible code in this directory.

本答案仅供参考评分标准，学生核心 **ML** 实现需独立完成。